

15주차 예습과제

8.6 토픽 모델링

- 토픽 모델링 : 문서 집합에 숨어 있는 주제를 찾아내는 것
 - 많은 양의 문서가 있을 때, 사람이 이 문서를 달 읽고 핵심 주제를 찾는데 많은 시간이 소요됨
 - 머신러닝 기반의 토픽 모델링을 적용해 숨어 있는 중요 주제를 효과적으로 찾아낼 수 있음 → 숨겨진 주제를 효과적으로 표현할 수 있는 중심 단어를 함축적으로 추출함.
- 토픽 모델링의 종류
 - LSA (Latent Semantic Analysis) : 머신러닝 기반의 토픽 모델링에서 자주 사용
 - LDA (Latent Dirichlet Allocation) : 문서의 집합으로부터 어떤 토픽이 존재하는지를 알아내기 위한 알고리즘
 - LDA 수행 과정
 1. 사용자가 알고리즘에게 토픽의 개수 (k)를 알려줌
 2. 모든 단어를 k개 중 하나의 토픽에 할당
 3. 모든 문서의 모든 단어에 대해 아래의 사항 반복
 - 어떤 문서의 각 단어 w 는어떤 문서의 각 단어 w 는 자신은 잘못된 토픽에 할당되어져 있지만, 다른 단어들은 전부 올바른 토픽에 할당되어져 있는 상태라고 가정합니다. 이에 따라 단어 w 는 아래의 두 가지 기준에 따라서 토픽이 재할당됩니다.
 - $p(\text{topic } t \mid \text{document } d)$: 문서 d 의 단어들 중 토픽 t 에 해당하는 단어들의 비율
 - $p(\text{word } w \mid \text{topic } t)$: 각 토픽들 t 에서 해당 단어 w 의 분포


8.7 문서 군집화

- 문서 군집화(Document Clustering) : 비슷한 텍스트 구성의 문서를 군집화하는 것
 - 동일한 군집에 속하는 문서를 같은 카테고리 소속으로 분류할 수 있으므로 앞의 텍스트 분류 기반의 문서 분류와 유사함.
- 군집화를 진행하면, 각 군집에 속한 문서는 핵심 단어를 주축으로 군집화되어 있음.

- KMeans 객체는 각 군집을 구성하는 단어 피처가 군집의 중심 (Centroid)를 기준으로 얼마나 가깝게 위치해있는지 clusterscenters라는 속성으로 제공

8.8 문서 유사도

- 코사인 유사도 : 문서 간 유사도 측정 시 일반적으로 사용
 - 벡터와 벡터 간의 유사도를 비교할 때 벡터의 크기보다 벡터의 상호 방향성이 얼마나 유사한지에 기반
 - 두 벡터 사이의 사잇각을 구해 얼마나 유사한지 수치로 적용
- 두 벡터의 사잇각에 따라 상호관계는 유사하거나, 관련이 없거나, 아예 반대가 될 수도 있음.



- 두 벡터 A, B의 코사인 값은 다음과 같이 구할 수 있음
 - 두 벡터의 내적 값을 두 벡터의 크기를 곱한 값의 코사인 각도 값을 곱한 것
- 유사도 $\cos\theta$ = 두 벡터의 내적을 총 벡터 크기의 합으로 나눈 것

$$\text{similarity} = \cos\theta = \frac{A \cdot B}{\|A\| \|B\|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}}$$

- 코사인 유사도가 많이 사용되는 이유: 문서를 피처 벡터화 변환하면 차원이 많은 희소 행렬이 될 가능성이 높는데, 희소 행렬 기반에서 문서와 문서 벡터 간의 크기에 기반한 유사도 지표는 정확도가 떨어지기 쉬움 (ex. 유클리드 유사도)

8.9 한글 텍스트 처리

- 한글 언어 처리의 어려움 : 띄어쓰기, 다양한 조사
- 한글의 경우 띄어쓰기를 잘못하면, 의미가 왜곡되어 전달될 수 있음.
 - ex) 아버지가 방에 들어가신다. → 띄어쓰기 잘못하면 아버지 가방에 들어가신다로 됨.
- 조사는 주어나 목적어를 위해 추가되는데, 워낙 경우의 수가 많아서 어근 추출 등의 전처리 시 제거하기가 까다로움.
 - ex) 집이라는 단어를 기준, 집이, 집으로, 집에, 집에서 등의 다양한 조사 존재
- KonNLPy: 파이썬의 대표적인 한글 형태소 패키지
 - 형태소 분석: 말을 형태소(단어로서 의미를 가지는 최소 단위) 어근 단위로 쪼개고 품사 태깅을 부착하는 작업