

16주차 예습과제

9.1 추천 시스템의 개요와 배경

- 추천 시스템은 콘텐츠 기반 필터링과 협업 필터링으로 나뉨
- 협업 필터링은 다시 최근접 이웃 방식과 잠재 요인 방식으로 구분
- 최근에는 콘텐츠 기반 방식과 협업 필터링을 결합한 하이브리드 방식도 널리 활용

9.2 콘텐츠 기반 필터링 추천 시스템

- 콘텐츠 기반 필터링은 사용자가 선호한 아이템과 유사한 콘텐츠를 가진 다른 아이템을 추천
- 예: '컨택트'(SF, 미스터리), '프로메테우스'(SF, 액션, 스릴러)에 높은 점수를 준 경우
 - 추천 시스템은 장르, 감독, 출연진, 키워드 등을 분석
 - 유사 콘텐츠를 가진 '블레이드 러너 2049'와 같은 영화를 추천 가능

9.3 최근접 이웃 협업 필터링

: 사용자가 아이템에 남긴 평점, 구매 이력 등 행동 데이터를 바탕으로 추천을 수행

- 핵심 목적: 누적된 사용자 행동을 통해 생성된 사용자-아이템 평점 행렬을 이용해 사용자가 아직 평가하지 않은 아이템의 선호도를 예측하는 것
- 추천 과정은 사용자-아이템 평점 행렬 데이터에만 의존
 - 행(row): 개별 사용자
 - 열(column): 개별 아이템
 - 행렬은 일반적으로 희소한 다차원 행렬 형태를 가짐
- 메모리 기반 협업 필터링 방식에는 다음 두 가지가 있음
 - 사용자 기반: 특정 사용자와 취향이 유사한 다른 사용자들이 구매한 상품을 추천
 - 아이템 기반: 해당 상품을 선택한 사용자들이 함께 선택한 다른 상품을 추천하며, 일반적으로 사용자 기반보다 성능이 더 안정적
- 추천을 위해 특정 사용자와 유사도가 높은 사용자들을 Top-N으로 선정
 - 사용자 간 유사도는 행동 패턴을 기준으로 계산

- 아이템이 가진 고유한 속성과는 무관하게 사용자들이 실제로 해당 아이템을 선호하거나 비선호한 정도만을 기준으로 추천이 이루어지기 때문에 주의

9.4 잠재 요인 협업 필터링

: 사용자-아이템 평점 행렬에서 잠재 요인을 추출해 추천을 예측하는 기법

- 행렬 분해: 대규모 행렬을 SVD 등 차원 축소 기법으로 분해하여 잠재 요인을 도출
 - 잠재 요인은 평점 데이터만으로 도출되며, 구체적으로 정의되기보다는 수학적으로 계산되는 특성
 - 잠재 요인 협업 필터링은 사용자-아이템 희소 행렬을 저차원 밀집 행렬 두 개로 분해
 - 사용자-잠재 요인 행렬
 - 아이템-잠재 요인 행렬의 전치 행렬(잠재 요인-아이템 행렬)
 - 이 두 행렬의 **내적**을 통해 새로운 예측 사용자-아이템 평점 행렬을 생성 → 사용자가 아직 평가하지 않은 아이템의 예측 평점을 계산
 - 사용자-아이템 평점 행렬 $R(M \times N)$ 은 사용자-잠재 요인 행렬 $P(M \times K)$ 와 잠재 요인-아이템 행렬 $Q.T(K \times N)$ 로 분해
 - SVD 방식이 일반적으로 사용 → NaN값이 없는 행렬에만 적용 가능
- ⇒ SGD / ALS 방식 사용
- SGD를 활용한 행렬 분해

: P와 Q 행렬로 계산된 예측 R 행렬 값이 실제 R 행렬 값과 가장 최소의 오류를 가질 수 있도록 반복적인 비용함수 최적화를 통해 P와 Q를 유추해내는 것

 1. P와 Q 행렬을 임의의 값으로 설정
 2. P와 Q.T를 곱해 예측 R 행렬을 계산하고 오류 값 계산
 3. 이 오류를 최소화하기 위해 P와 Q 값을 업데이트
 4. 오류가 충분히 줄어들 때까지 2, 3단계를 반복

9.8 파이썬 추천 시스템 패키지 - Surprise

[주요 모듈]

API 명	내용
<code>Dataset.load_builtin</code> (<code>name='ml-100k'</code>)	무비렌즈 아카이브 FTP 서버에서 무비렌즈 데이터를 내려받습니다. ml-100k, ml-1M를 내려받을 수 있습니다. 일단 내려받은 데이터는 <code>.surprise_data</code> 디렉터리 밑에 저장되고, 해당 디렉터리에 데이터가 있으면 FTP에서 내려받지 않고 해당 데이터를 이용합니다. 입력 파라미터인 <code>name</code> 으로 대상 데이터가 ml-100k인지 ml-1m인지를 입력합니다(<code>name='ml-100k'</code>). 디폴트는 ml-100k입니다.

API 명	내용
<code>Dataset.load_from_file</code> (<code>file_path, reader</code>)	OS 파일에서 데이터를 로딩할 때 사용합니다. coma, 탭 등으로 칼럼이 분리된 포맷의 OS 파일에서 데이터를 로딩합니다. 입력 파라미터로 OS 파일명, Reader로 파일의 포맷을 지정합니다.
<code>Dataset.load_from_df</code> (<code>df, reader</code>)	판다스의 DataFrame에서 데이터를 로딩합니다. 파라미터로 DataFrame을 입력받으며 DataFrame 역시 반드시 3개의 칼럼인 사용자 아이디, 아이템 아이디, 평점 순으로 칼럼 순서가 정해져 있어야 합니다. 입력 파라미터로 DataFrame 객체, Reader로 파일의 포맷을 지정합니다.

[주요 생성 파라미터]

- `line_format (string)`: 칼럼을 순서대로 나열합니다. 입력된 문자열을 공백으로 분리해 칼럼으로 인식합니다.
- `sep (char)`: 칼럼을 분리하는 분리자이며, 디폴트는 `'\t'`입니다. 판다스 DataFrame에서 입력받을 경우에는 기재할 필요가 없습니다.
- `rating_scale (tuple, optional)`: 평점 값의 최소 ~ 최대 평점을 설정합니다. 디폴트는 (1, 5)이지만 ratings.csv 파일의 경우는 최소 평점이 0.5, 최대 평점이 5이므로 (0.5, 5)로 설정했습니다.

[Surprise 추천 알고리즘 클래스]

클래스명	설명
SVD	행렬 분해를 통한 잠재 요인 협업 필터링을 위한 SVD 알고리즘.
KNNBasic	최근접 이웃 협업 필터링을 위한 KNN 알고리즘.
BaselineOnly	사용자 Bias와 아이템 Bias를 감안한 SGD 베이스라인 알고리즘.

⇒ SVD 클래스 파라미터:

- `n_factors`: 잠재 요인 개수
- `n_epochs`: 반복 횟수
- `biased`: 베이스라인 사용자 편향 적용 여부

- 베이스라인 평점: 개인의 성향을 반영해 아이템 평가에 편향성 요소를 반영하여 평점을 부과하는 것
⇒ 전체 평균 평점 + 사용자 편향 점수 + 아이템 편향 점수